

Organización de Datos

Resumen explicativo — Organización Secuencial

Materia: Organización y Estructura de Datos | Autores: Carlos Rico · Valeria A. Di Croce

1. ¿Qué es la Organización Secuencial?

La organización secuencial es la forma más antigua y simple de almacenar información en archivos. Surgió cuando las cintas magnéticas eran el único medio de almacenamiento permanente, y su característica fundamental es que los registros se guardan uno tras otro, en el orden en que fueron escritos.

Aunque hoy coexiste con otras organizaciones más sofisticadas, sigue siendo ampliamente utilizada en archivos transaccionales de solo lectura-escritura al final, como **logs** y **bitácoras**.

Características principales

- **Acceso secuencial:** los registros se leen uno por uno desde el inicio; puede optimizarse con acceso relativo.
- **Longitud fija o variable:** el comportamiento del archivo varía según el tipo de registro.
- **Almacenamiento en bloques:** los registros de longitud variable actualizables se agrupan en bloques de disco.

2. Registros Desordenados

En un archivo desordenado los registros no siguen ningún criterio de orden. Es la forma más simple de operar un archivo secuencial.

Operaciones básicas

- **Creación:** se cargan registros sin validar unicidad ni buscar espacio libre.
- **Alta (append):** se abre el archivo y se posiciona al final para escribir el nuevo registro.
- **Recuperación:** se lee desde el principio hasta encontrar el registro o llegar al final. Solo permite búsqueda lineal $O(n)$.

Actualización

- **Inserción:** se verifica que el registro no exista y se graba en el primer espacio libre.
- **Modificación:** se localiza el registro, se actualiza en memoria y se reescribe la unidad de disco.

- **Eliminación en RRLF (longitud fija):** se mueve el último registro del archivo a la posición eliminada y se trunca el archivo.
- **Eliminación en RRLV (longitud variable):** se compacta el bloque donde estaba el registro y se reescribe.

3. Registros Ordenados por Identificador

Mantener los registros ordenados por su clave (identificador) permite aprovechar algoritmos más eficientes y simplifica el procesamiento en lote. Sin embargo, las operaciones de actualización se vuelven más costosas.

Ventajas

- Búsqueda binaria $O(\log n)$ en lugar de lineal $O(n)$.
- Apareo (merge) eficiente con otros archivos.
- Cortes de control en un único recorrido para reportes con subtotales.

Desventajas

- Las altas obligan a reconstruir el archivo o a diferirlas en un archivo de novedades.
- Las bajas lógicas requieren re-estructuración periódica; las bajas físicas implican reconstrucción o también pueden diferirse.

Manipulación de registros ordenados

- **Creación:** los registros son previamente validados y ordenados mediante ordenamiento externo.
- **Recuperación:** búsqueda lineal (con corte temprano) o binaria.
- **Reportes:** cortes de control con agrupación, conteo, suma y promedio en un solo recorrido.

Actualización — Inserción

- **Directa:** crear archivo nuevo → copiar registros menores → insertar el nuevo → copiar el resto → renombrar.
- **Por novedades:** acumular altas en un archivo auxiliar ordenado y luego mezclar con el maestro.

Eliminación en registros ordenados

- **Directa:** igual que la inserción directa pero omitiendo el registro a eliminar.
- **Por novedades:** acumular bajas y eliminar por mezcla.
- **Por marcado:** marcar el registro (cambio de signo del ID o campo de estado). Requiere depuración periódica.

Buena práctica: realizar siempre copia de respaldo antes de cualquier operación masiva.

4. Corte de Control

El corte de control es una técnica de procesamiento que opera sobre registros previamente ordenados por uno o más campos. Permite agruparlos en subconjuntos definidos por el criterio de orden y calcular totales y subtotales en un único recorrido del archivo.

Su aplicación más habitual es la generación de reportes: se utilizan contadores, acumuladores y promedios, informando subtotales por cada nivel de agrupación y totales generales al final.

Algoritmo general

- Se lee el primer registro y se guarda la clave de nivel 1 (anterior1).
- Mientras la clave no cambie, se procesan registros del mismo grupo (nivel 2, nivel 3...).
- Al detectar un cambio de clave, se vuelcan los totales acumulados del nivel correspondiente.
- El proceso continúa hasta el fin del archivo, imprimiendo el total general al salir.

5. Apareo de Archivos (Merge)

El apareo consiste en combinar dos archivos ordenados (relacionados por su identificador) para generar un tercero. Es la base de operaciones como las altas en lote, bajas masivas y actualización del maestro.

Tipos de apareo

- **Intersección ($A \cap B$):** conserva solo los registros presentes en ambos archivos. Útil para, por ejemplo, encontrar clientes activos que también son morosos.
- **Diferencia ($A - B$):** conserva los registros del maestro que no aparecen en el archivo de novedades. Útil para procesamiento de bajas.
- **Unión ($A \cup B$):** combina todos los registros de ambos archivos (altas e inserciones), generando el maestro actualizado.

Requisito esencial: ambos archivos deben estar ordenados por la misma clave antes de aparearlos.

6. Ordenamiento

El ordenamiento es un prerequisite para la mayoría de las técnicas vistas (búsqueda binaria, apareo, corte de control). Se clasifica según tres criterios:

- **Lugar:** interno (en RAM) o externo (en disco, cuando los datos no caben en memoria).

- **Tiempo:** natural (tiempo mínimo con entrada ordenada) o no natural (tiempo mínimo con entrada inversa).
- **Estabilidad:** estable (mantiene el orden relativo de elementos con igual clave) o inestable.

Algoritmos clásicos

Burbuja: compara elementos adyacentes e intercambia si están en orden incorrecto. Simple pero $O(n^2)$; útil solo con fines educativos.

Inserción: divide la lista en parte ordenada y desordenada, insertando cada elemento en su lugar. Eficiente para listas pequeñas o casi ordenadas.

Merge Sort: divide recursivamente la lista en mitades, las ordena y las mezcla. Estable y $O(n \log n)$.

Quick Sort: elige un pivote, particiona alrededor de él y ordena cada partición recursivamente. Muy rápido en la práctica pero inestable.

Shell Sort: mejora la inserción comparando elementos separados por intervalos decrecientes ($n/2$, $n/4$... hasta 1). Creado por Donald Shell.

7. Ordenamiento Externo (en Disco)

Cuando los datos a ordenar no caben en RAM, se recurre al ordenamiento externo. El proceso es más lento porque implica múltiples lecturas y escrituras en disco, y requiere al menos 3 archivos auxiliares.

Mezcla Directa (External Merge Sort)

Es el método clásico. Se divide en dos fases:

- **Fase 1 — Generación de runs:** se leen bloques del tamaño que permite la RAM, se ordenan internamente y se vuelcan a disco como 'runs' ordenados (run_01, run_02...).
- **Fase 2 — Fusión:** se abren k runs simultáneamente, se selecciona siempre el menor registro de las cabeceras, se escribe en un buffer de salida y se recarga cuando se agota. Se repite hasta obtener un único archivo ordenado.

Ventaja: controlado y predecible. Desventaja: no aprovecha el orden ya existente en los datos.

Mezcla Natural (Natural Merge Sort)

Más inteligente: detecta y explota secuencias ya ordenadas dentro del archivo original.

- **Paso 1:** se recorre el archivo y se detectan subsecuencias crecientes (runs naturales), que se distribuyen alternadamente entre dos auxiliares (aux1, aux2).
- **Paso 2:** se aparean los runs de aux1 y aux2 formando secuencias más largas.
- **Paso 3:** se repite hasta que quede un único run que abarque todo el archivo.

*Ventaja: requiere menos pasadas si el archivo ya tiene tramos ordenados (ej. logs por fecha).
Desventaja: igual de costoso que Mezcla Directa si los datos son completamente aleatorios.*

8. Resumen comparativo final

Altas: en archivos desordenados $O(1)$ por append; en ordenados son costosas (reconstrucción) o se difieren con novedades + apareo.

Búsqueda: en desordenados solo búsqueda lineal $O(n)$; en ordenados binaria $O(\log n)$ o lineal con corte temprano.

Bajas: en desordenados RRLF por swap del último + truncado, RRLV por compactación de bloque; en ordenados reconstrucción, novedades o marcado + depuración.

Reportes/Cortes: costosos en archivos desordenados; naturales y en un solo paso en archivos ordenados.

Conclusión general: la elección entre archivo ordenado y desordenado depende del patrón de uso. Si predominan las consultas y los reportes → ordenado. Si predominan las altas masivas y las búsquedas son raras → desordenado.